

Implementasi Machine Learning dengan Metode SVM untuk Membedakan Suara AI dan Manusia

Clayvent Yuuki William
Binus ASO School of Engineering
Tangerang, Alam Sutera

Dwi Naya Syah Hary
Binus ASO School of Engineering
Tangerang, Alam Sutera

Louis Oliver
Binus ASO School of Engineering
Tangerang, Alam Sutera

Rasyhad Aqil Wiryawan
Binus ASO School of Engineering
Tangerang, Alam Sutera

Avriel Zara Xaviera
Binus ASO School of Engineering
Tangerang, Alam Sutera

ABSTRAK

Perkembangan pesat teknologi *Artificial Intelligence* (AI) dalam *Text-to-Speech* (TTS) telah meningkatkan realisme suara sintesis secara signifikan, yang memunculkan tantangan baru terkait keamanan dan keaslian konten audio, seperti maraknya kasus *deepfake*. Penelitian ini bertujuan untuk mengembangkan sistem klasifikasi audio yang mampu membedakan antara suara manusia asli dan suara hasil generasi AI menggunakan algoritma *Support Vector Machine* (SVM). Metode yang diusulkan memanfaatkan ekstraksi fitur *Mel-Frequency Cepstral Coefficients* (MFCC) untuk menganalisis karakteristik spektral dan akustik dari sinyal suara. Model SVM dilatih menggunakan kernel *Radial Basis Function* (RBF) dengan data yang dibagi menjadi himpunan *training* dan *testing*. Hasil eksperimen menunjukkan performa model yang efektif, dengan akurasi pada fase pelatihan (*training*) mencapai 97,76%. Pada fase pengujian (*testing*) terhadap data baru, sistem berhasil mencapai akurasi keseluruhan sebesar 90,77%, dengan tingkat pengenalan suara AI sebesar 93,93% dan suara manusia sebesar 87,60%. Penelitian ini menyimpulkan bahwa kombinasi fitur MFCC dan klasifikasi SVM merupakan pendekatan yang andal untuk mendeteksi manipulasi suara digital.

I. LATAR BELAKANG

Perkembangan teknologi *Artificial Intelligence* (AI) yang sangat pesat telah membawa kemajuan signifikan dalam bidang sintesis suara (*speech synthesis*), khususnya melalui model generatif *Text-to-Speech* (TTS). Teknologi ini memungkinkan sistem AI menghasilkan suara yang sangat menyerupai manusia, baik dari segi intonasi, emosi, maupun kejelasan artikulasi [1] [2]. Namun, peningkatan realisme suara hasil AI tersebut menimbulkan tantangan baru terkait keaslian dan kepercayaan terhadap konten audio yang beredar di masyarakat. Kasus penipuan suara, penyebaran berita palsu, hingga *deepfake audio* semakin marak terjadi, sehingga diperlukan sistem yang mampu membedakan antara suara manusia asli dan suara hasil generasi AI.

Untuk mengatasi permasalahan tersebut, analisis sinyal suara menjadi pendekatan yang penting dalam mengidentifikasi karakteristik akustik dan pola spektral yang membedakan kedua jenis suara tersebut. Di antara berbagai metode klasifikasi berbasis fitur akustik, algoritma *Support Vector Machine* (SVM) terbukti efektif digunakan. SVM sangat sesuai untuk permasalahan

klasifikasi biner karena kemampuannya dalam mencari *hyperplane* optimal yang memaksimalkan margin antar dua kelas data, sehingga meningkatkan kemampuan generalisasi model [3].

Beberapa penelitian sebelumnya telah menunjukkan efektivitas SVM dalam mendeteksi manipulasi suara digital. Menurut M. A. Khder, S. Shorman, D. T. Aldoseri, dan M. M. Saeed dalam penelitian berjudul “Improving Deepfake Audio Detection: A Support Vector Machine (SVM) Classifier” (2023), algoritma SVM terbukti sangat efektif dalam mengenali pola akustik yang halus dan kompleks pada suara hasil manipulasi digital [4]. Sementara itu, L. Bahatti, O. Bouattane, M. El Houssine Ech-Chhibat, dan M. H. Zaggaf dalam penelitian berjudul “An Efficient Audio Classification Approach Based on Support Vector Machines” (2016) menjelaskan bahwa SVM memiliki kinerja yang lebih baik dibandingkan metode tradisional seperti k-nearest neighbor (KNN) dan Naïve Bayes, karena mampu memberikan tingkat akurasi dan generalisasi yang tinggi meskipun data pelatihan terbatas [5].

Penelitian-penelitian yang lebih mutakhir juga memperkuat relevansi SVM dalam konteks deteksi *deepfake audio*. Studi oleh Nilakshi Jain et al. (2024) menunjukkan bahwa kombinasi fitur Mel-Frequency Cepstral Coefficients (MFCC) dengan klasifikasi SVM mencapai akurasi 97,28 % pada dataset FoR (for-original) yang berisi lebih dari 195.000 sampel suara manusia dan sintetis [6]. Penelitian oleh Borade et al. (2024) mengombinasikan SVM dengan mekanisme *attention-based neural networks* dan menghasilkan peningkatan ketahanan terhadap variasi manipulasi suara [7]. Selain itu, penelitian SafeEar oleh Li et al. (2024) menunjukkan bahwa deteksi *deepfake* dapat dilakukan secara *privacy-preserving* hanya dengan menganalisis aspek akustik seperti timbre dan prosodi, tanpa perlu memproses konten semantik suara [8].

Penggunaan metode SVM memiliki sejumlah keunggulan dalam membedakan suara manusia dengan suara hasil AI. SVM dapat menangani data berdimensi tinggi, termasuk berbagai fitur audio seperti *Mel-Frequency Cepstral Coefficients* (MFCCs), variasi nada (*pitch variation*), dan kontras spektral (*spectral contrast*). Selain itu, penggunaan *kernel trick* memungkinkan SVM untuk mengenali batas keputusan non-linear yang kompleks, suatu kemampuan yang sangat penting karena perbedaan karakteristik antara suara manusia dan AI seringkali sangat halus dan tidak dapat dipisahkan secara linear. Di samping itu, SVM juga menunjukkan performa yang stabil pada dataset berukuran sedang, dengan efisiensi komputasi yang lebih baik dibandingkan model *deep learning* yang memerlukan data dalam jumlah besar.

Dengan demikian, penelitian ini bertujuan untuk mengimplementasikan algoritma *Support Vector Machine (SVM)* dalam sistem deteksi dan klasifikasi suara untuk membedakan antara suara manusia dan suara yang dihasilkan oleh AI melalui analisis sinyal akustik. Pendekatan ini diharapkan dapat berkontribusi dalam pengembangan sistem verifikasi audio yang andal serta mendukung upaya mitigasi terhadap penyalahgunaan teknologi sintesis suara di era digital saat ini.

II. PROPOSED SYSTEM

A. Data Gathering




Fig1. Raw signal plot suara AI & MANUSIA

Kedua gambar menampilkan Sinyal Mentah (*Raw Signal*) berupa deretan pulsa energi tajam yang berulang secara periodik yang paling sering merepresentasikan gelombang suara atau getaran mekanis. Grafik ini menunjukkan bagaimana amplitudo (kekuatan) sinyal berubah. Pola pulsa yang konsisten menunjukkan adanya aktivitas periodik yang stabil dari sumbernya. Perbedaan utamanya adalah Gambar 1 menunjukkan rekaman dengan kekuatan yang relatif stabil di mana dimulai dengan lonjakan yang besar di awal dan perlahan menurun, sedangkan Gambar 2, meskipun terlihat stabil, namun pulsa menunjukkan adanya perubahan kekuatan pulsa sesaat di tengah rekaman dimana pada bagian awal dan akhir sering terjadi kenaikan kekuatan yang tiba tiba ataupun kadang trjadi lonjakan di tengah pada gambar signal, mengindikasikan adanya modulasi atau perubahan intensitas sementara pada

sumber sinyal yang direkam.

B. Data Sampling

```
[spp, fs] = audioread('AI1.mp3');
figure(1)
plot(spp);
title('Raw Signal');
ylabel('Amplitude(v)');
xlabel('time(s)');

[spp, fs] = audioread('REAL1.mp3');
figure(1)
plot(spp);
title('Raw Signal');
ylabel('Amplitude(v)');
xlabel('time(s)');
```

Fig 2. Code untuk plot raw signal graph

Perintah `audioread()` digunakan untuk membaca file audio yang bertujuan menghasilkan dua output, yaitu `spp` yang berisi data amplitudo sinyal, serta `fs` yang menunjukkan *sampling rate* (jumlah sampel per detik). Nilai `spp` kemudian diplot menggunakan fungsi `plot()` untuk menampilkan bentuk gelombang (*raw signal*). Judul dan label sumbu ditambahkan untuk memperjelas representasi data, di mana sumbu horizontal menunjukkan waktu (dalam detik), dan sumbu vertikal menunjukkan amplitudo sinyal (dalam *Volt*). Visualisasi ini digunakan untuk memastikan bahwa proses pengambilan sampel berhasil dan sinyal suara dapat diolah lebih lanjut pada tahap ekstraksi fitur.

Tujuan utamanya adalah menghitung atau mengekstrak serangkaian koefisien atau fitur dari setiap segmen data sinyal. Koefisien-koefisien ini, yang disimpan dalam variabel `c1` hingga `c20`, kemudian dapat digunakan untuk tugas-tugas seperti pengenalan ucapan, klasifikasi sinyal, atau analisis karakteristik sinyal.

C. Feature Extraction

```

fs = 44100;
for c = 1:20
    x = load(sprintf('spp20.txt', c));
    x = x(:);
    x = x / (max(abs(x)) + eps);
    x = filter([1-0.97], 1, x);

    wlen = round(0.025*fs);
    hop = round(0.010*fs);
    n = numel(x);
    n_f = floor((n-wlen)/hop);

    frames = zeros(n_f, wlen);
    win = hamming(wlen, 'periodic').';

    for i = 1:n_f
        s = (i-1)*hop + 1;
        frames(i,:) = x(s:s+wlen-1);
    end

    frames = frames .* win;

    ncep = 13; nbanks = 26;
    coeff = zeros(n_f, ncep);
    for i = 1:n_f
        tmp = v_melcepst(frames(i,:), fs, 'E', ncep, nbanks, wlen, wlen);
        coeff(i,:) = tmp(1, 1:ncep);
    end

    save(sprintf('spp20mels.txt', c), 'coeff', '-ascii');

    figure(1); clf;
    plot(coeff); axis xy; colorbar;
    xlabel('Frame'); ylabel('Coeff'); title(sprintf('MFCC spp2', c));
end

fs = 44100;
for c = 1:20
    x = load(sprintf('bspp1.txt', c));
    x = x(:);
    x = x / (max(abs(x)) + eps);
    x = filter([1-0.97], 1, x);

    wlen = round(0.025*fs);
    hop = round(0.010*fs);
    n = numel(x);
    n_f = floor((n-wlen)/hop);

    frames = zeros(n_f, wlen);
    win = hamming(wlen, 'periodic').';

    for i = 1:n_f
        s = (i-1)*hop + 1;
        frames(i,:) = x(s:s+wlen-1);
    end

    frames = frames .* win;

    ncep = 13; nbanks = 26;
    coeff = zeros(n_f, ncep);
    for i = 1:n_f
        tmp = v_melcepst(frames(i,:), fs, 'E', ncep, nbanks, wlen, wlen);
        coeff(i,:) = tmp(1, 1:ncep);
    end

    save(sprintf('bspp1mels.txt', c), 'coeff', '-ascii');

    figure(1); clf;
    plot(coeff); axis xy; colorbar;
    xlabel('Frame'); ylabel('Coeff'); title(sprintf('MFCC bspp2', c));
end

```

Fig 3. Code untuk feature extraction

Fungsi utama dari kode ini adalah menghitung dan menyimpan koefisien *Mel-Frequency Cepstral Coefficients* (MFCC) dari sejumlah file suara yang berulang (melalui loop for c = 120). MFCC adalah vektor ciri yang paling umum digunakan untuk merepresentasikan karakteristik unik suara manusia (vokal *tract*) secara efisien.

Persiapan Data: Kode memuat file suara satu per satu, menyesuaikan volume rekaman (*normalisasi*), dan menajamkan suara frekuensi tinggi (*pre-emphasis*).

1. Pemotongan Sinyal: Suara yang panjang dipotong-potong menjadi frame-frame pendek yang saling tumpang tindih. Setiap potongan diberi bobot (*jendela*) agar analisis

frekuensi lebih akurat.

2. Ekstraksi Ciri (MFCC): Untuk setiap potongan suara, dihitung koefisien Mel-Frequency Cepstral Coefficients (MFCC). Koefisien ini adalah sidik jari akustik yang menangkap karakteristik unik dari rongga suara (vokal *tract*) seseorang, meniru cara telinga manusia mendengar.

Penyimpanan Hasil: Koefisien ciri (MFCC) yang sudah diekstrak ini kemudian disimpan dalam file terpisah untuk digunakan dalam pelatihan sistem SVM agar dapat membedakan antara suara AI dan Manusia. Kode juga menampilkan grafik visual dari ciri yang telah diekstrak.




Fig 4. MFCC graph

Kedua gambar menampilkan visualisasi Koefisien Cepstral Frekuensi Mel (MFCC), yang merupakan fitur akustik standar yang digunakan untuk merepresentasikan karakteristik suara dalam sistem pengenalan ucapan. Sumbu-X (Frame) menunjukkan waktu, di mana sinyal suara dibagi menjadi bingkai-bingkai berurutan, dan Sumbu-Y (Coeff) menunjukkan amplitudo dari setiap koefisien. Setiap garis berwarna mewakili satu koefisien MFCC tertentu (misalnya, MFCC 1 hingga MFCC 12 atau lebih), menunjukkan bagaimana fitur-fitur ini berubah seiring waktu. Plot MFCC spp2 dan MFCC bspp2

menunjukkan bahwa karakteristik akustik dari dua segmen suara yang berbeda telah diekstraksi. Variasi signifikan dalam nilai dan pola koefisien antar-frame (terutama garis atas/koefisien orde rendah) di kedua plot mencerminkan perbedaan isi fonetik atau kualitas suara, yang merupakan dasar bagi algoritma untuk membedakan antara kata atau ucapan yang berbeda.

D. SVM Training

```
% === PENGATURAN KONSTANTA PEMBAGIAN DATA ===
NUM_TOTAL_FILES = 20;
NUM_TRAIN = 15; % Jumlah file untuk Training (1 sampai 15)
NUM_TEST = 5;   % Jumlah file untuk Testing (16 sampai 20)
```

```
if i <= NUM_TRAIN
    % Data Training (1-15)
    train_A_cell{end+1} = data_A;
    train_B_cell{end+1} = data_B;
else
    % Data Testing (16-20)
    test_A_cell{end+1} = data_A;
    test_B_cell{end+1} = data_B;
end
```

Fig 5. Code untuk pisah training dan testing data

Pada tahap ini, sistem menetapkan konfigurasi pembagian dataset yang akan digunakan dalam proses pelatihan dan pengujian model. Dataset terdiri dari total 20 file fitur hasil ekstraksi Mel-Frequency Cepstral Coefficients (MFCC).

Setelah konfigurasi pembagian data ditentukan, proses pemisahan data training dan data testing dilakukan secara sekuensial berdasarkan indeks file. Pemisahan ini diimplementasikan menggunakan struktur kondisi *if-else*, di mana data dengan indeks file 1 hingga 15 dimasukkan ke dalam kelompok *training*, sementara data dengan indeks file 16 hingga 20 dimasukkan ke dalam kelompok *testing*. Setiap data dari kedua kelas disimpan secara terpisah dalam cell array masing-masing, sehingga menjamin bahwa data testing tidak pernah digunakan selama proses pelatihan model *Support Vector Machine* (SVM).

```
% --- Penyusunan Data Training (xapp) ---
xappa = cell2mat(train_A_cell');
xappb = cell2mat(train_B_cell');
xapp = [xappa; xappb];

% Pelabelan Data Training (yapp): Kelas A=1, Kelas B=-1
yapp = [1*ones(length(xappa),1); -1*ones(length(xappb),1)];

% --- Penyusunan Data Testing (xtest) ---
xtest_A_raw = cell2mat(test_A_cell');
xtest_B_raw = cell2mat(test_B_cell');
xtest = [xtest_A_raw; xtest_B_raw];

% Pelabelan Data Testing (y_true): Ground Truth
y_true = [1*ones(length(xtest_A_raw),1); -1*ones(length(xtest_B_raw),1)];
```

Fig 6. Code untuk Penyusunan dan Pelabelan Data Training

Data pelatihan disusun dengan menggabungkan hasil ekstraksi fitur dari kedua kelas ke dalam satu matriks input (xapp). Label kelas diberikan dalam bentuk numerik, di mana kelas A diberi label +1 dan kelas B diberi label -1. Pendekatan pelabelan biner ini memungkinkan proses klasifikasi dilakukan secara *supervised learning* menggunakan SVM.

Proses penyusunan data testing dilakukan dengan pendekatan yang serupa dengan data training. Data uji dari masing-masing kelas digabungkan ke dalam satu matriks input (xtest), sedangkan label kebenaran dasar (y_true) disusun menggunakan skema pelabelan yang sama, yaitu +1 untuk Kelas A dan -1 untuk Kelas B. Data testing ini tidak digunakan pada proses pelatihan, melainkan hanya digunakan pada tahap evaluasi untuk mengukur performa dan kemampuan generalisasi model.

```
c1 = fitcsvm(xapp, yapp, ...
    'KernelFunction', 'rbf', ...
    'BoxConstraint', 0.3, ... % Nilai yang seimbang
    'KernelScale', 'auto', ...
    'Standardize', true, ...
    'ClassNames', [-1, 1]);

fprintf('Pelatihan model selesai.\n');
```

Fig 7. Code untuk fitting training data ke model

Proses pelatihan dilakukan menggunakan fungsi *fitcsvm* pada MATLAB. Model SVM menggunakan kernel *Radial Basis Function* (RBF) untuk menangani pola data non-linear pada fitur MFCC. Fitur dinormalisasi menggunakan *Z-score standardization*, sedangkan parameter *BoxConstraint* digunakan untuk mengontrol *trade-off* antara margin dan kesalahan klasifikasi. Model yang dihasilkan bertujuan memisahkan dua kelas suara secara optimal pada ruang fitur berdimensi tinggi.

```
[label_train, ~] = predict(c1, xapp);

% Hitung Akurasi Keseluruhan Testing
accuracy_total = 100 * sum(label_test == y_true) / length(y_true);
```

Fig 8. Code untuk menghitung akurasi pengenalan pada fase training

Setelah proses pelatihan model SVM selesai, dilakukan evaluasi terhadap data training untuk mengetahui sejauh mana model mampu mempelajari pola dari data yang digunakan saat pelatihan. Model digunakan kembali untuk memprediksi data training, kemudian hasil prediksi dibandingkan dengan label sebenarnya. *Confusion matrix* dibentuk untuk menganalisis kesalahan klasifikasi, dan akurasi keseluruhan training dihitung sebagai persentase jumlah data yang diklasifikasikan dengan benar terhadap total data training.

E. SVM Testing

```
% Prediksi pada data uji
[label_test, ~] = predict(cl, xtest);

% Akurasi Keseluruhan Training
accuracy_train_total = 100 * sum(label_train == yapp) / length(yapp);
```

Fig 9. Code untuk proses pengujian (testing) data ke model SVM

Pada tahap pengujian, model SVM yang telah dilatih digunakan untuk memprediksi data uji yang tidak pernah dilibatkan dalam proses pelatihan. Prediksi dilakukan menggunakan fungsi predict pada MATLAB, kemudian hasil prediksi dibandingkan dengan label sebenarnya untuk menghitung akurasi pengujian. Nilai akurasi ini merepresentasikan kemampuan generalisasi model dalam membedakan suara manusia dan suara AI.

III. Experiment Result

Training and Classification Performance

```
=== 3. EVALUASI MODEL PADA DATA TRAINING (1-15) ===
Akurasi Keseluruhan Data Training: 97.76%
Persentase Akurasi Kelas A (ssp): 97.36%
Persentase Akurasi Kelas B (bssp): 98.15%
-----
```

Fig 10. Hasil output testing dimana model predict kelas A

Model *Support Vector Machine* (SVM) yang telah dilatih menggunakan kernel *Radial Basis Function* (RBF) menunjukkan performa yang sangat baik pada data training. Hasil evaluasi menunjukkan bahwa model mencapai akurasi keseluruhan sebesar 97.76%. Nilai akurasi yang tinggi ini mengindikasikan bahwa model mampu mempelajari pola fitur MFCC dari kedua kelas suara secara efektif.

Selain akurasi keseluruhan, dilakukan pula evaluasi akurasi per kelas untuk melihat konsistensi performa model. Hasil pengujian menunjukkan bahwa akurasi Kelas A (ssp) mencapai 97.36%, sedangkan akurasi Kelas B (bssp) mencapai 98.15%. Kedua nilai ini relatif seimbang, yang menunjukkan bahwa model tidak mengalami kecenderungan klasifikasi terhadap salah satu kelas pada fase pelatihan.

```
=== 4. EVALUASI MODEL PADA DATA UJI (16-20) ===
Akurasi Keseluruhan Data Testing: 90.77%

Confusion Matrix (Baris: True Class, Kolom: Predicted Class)
| Prediksi B (-1) | Prediksi A (1)
B |          332 |          47
A |          23 |          356

Persentase Akurasi Kelas A (ssp): 93.93%
Persentase Akurasi Kelas B (bssp): 87.60%
=====
```

Fig 11. Hasil output testing dimana model predict kelas B

Hasil pengujian menunjukkan bahwa model SVM memperoleh akurasi keseluruhan sebesar 90.77% pada data testing. Nilai ini mencerminkan bahwa model tetap mampu mengklasifikasikan suara manusia dan suara AI dengan tingkat ketepatan yang tinggi meskipun dihadapkan pada data baru.

Analisis lebih lanjut dilakukan menggunakan confusion matrix untuk melihat detail kesalahan klasifikasi. Berdasarkan confusion matrix, sebanyak 356 sampel Kelas A dan 332 sampel Kelas B berhasil diklasifikasikan dengan benar. Namun, terdapat 23 sampel Kelas A yang salah diklasifikasikan sebagai Kelas B, serta 47 sampel Kelas B yang salah diklasifikasikan sebagai Kelas A. Kesalahan ini menunjukkan adanya sebagian karakteristik fitur suara AI yang memiliki kemiripan spektral dengan suara manusia.

Berdasarkan hasil confusion matrix tersebut, diperoleh akurasi per kelas pada data testing, yaitu 93.93% untuk Kelas A (ssp) dan 87.60% untuk Kelas B (bssp).

Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa implementasi algoritma *Support Vector Machine* (SVM) dengan fitur *Mel-Frequency Cepstral Coefficients* (MFCC) mampu membedakan suara manusia dan suara hasil generasi *Artificial Intelligence* (AI) dengan tingkat akurasi yang tinggi. Proses klasifikasi dilakukan melalui tahapan pengambilan data suara, ekstraksi fitur MFCC, pemisahan data training dan testing, pelatihan model SVM, serta evaluasi performa menggunakan data uji yang tidak pernah dilibatkan dalam proses pelatihan.

Hasil evaluasi menunjukkan bahwa model SVM mencapai akurasi keseluruhan sebesar 97,76% pada data training, yang menandakan bahwa model mampu mempelajari pola karakteristik akustik dari kedua kelas suara secara efektif. Pada tahap pengujian, model memperoleh akurasi keseluruhan sebesar 90,77%, yang mengindikasikan bahwa model memiliki kemampuan generalisasi yang baik terhadap data baru. Evaluasi per kelas menunjukkan bahwa model lebih akurat dalam mengenali Kelas A (suara AI) dengan akurasi 93,93%, dibandingkan Kelas B (suara manusia) dengan akurasi 87,60%. Perbedaan ini mengindikasikan adanya kemiripan karakteristik spektral pada sebagian suara AI yang menyerupai suara manusia, sehingga meningkatkan tingkat kesalahan klasifikasi.

Secara keseluruhan, penelitian ini membuktikan bahwa kombinasi fitur MFCC dan algoritma SVM dengan kernel *Radial Basis Function* (RBF) merupakan pendekatan yang efektif untuk tugas klasifikasi suara manusia dan suara AI. Meskipun demikian, masih terdapat ruang untuk peningkatan performa, khususnya pada pengenalan suara AI. Pengembangan lebih lanjut dapat dilakukan melalui penambahan jumlah dan

variasi data latih, optimasi parameter SVM, serta eksplorasi fitur akustik tambahan atau metode klasifikasi yang lebih kompleks. Dengan demikian, sistem yang dikembangkan pada penelitian ini berpotensi menjadi dasar bagi pengembangan sistem deteksi dan verifikasi audio yang lebih andal dalam menghadapi tantangan penyalahgunaan teknologi sintesis suara di era digital.

REFERENCES

- [1] A. Hamza, A. Rehman Javed, F. Iqbal, N. Kryvinska, A. S. Almadhor, Z. Jalil and R. Borghol, "Deepfake Audio Detection via MFCC Features Using Machine Learning," *IEEE Access*, vol. 10, pp. 134018-134028, 2022.
- [2] "Audio Deepfake Detection: What Has Been Achieved and What Lies Ahead," *Sensors*, vol. 25, no. 7, 2025.
- [3] L. Bahatti, O. Bouattane, M. El Houssine Ech-Chhibat, and M. H. Zaggaf, "An Efficient Audio Classification Approach Based on Support Vector Machines," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 7, no. 5, pp. 205-211, June 2016.
- [4] M. A. Khder, S. Shorman, D. T. Aldoseri, and M. M. Saeed, "Improving Deepfake Audio Detection: A Support Vector Machine (SVM) Classifier," *International Journal of Innovative Science and Artificial Engineering (IJISAE)*, 2023.
- [5] N. Jain, S. Sharma, and R. Sahu, "Improving Deepfake Audio Detection Using MFCC and SVM Classifier," *Harbin Engineering Journal*, vol. 45, no. 2, pp. 211–218, 2024.
- [6] R. Borade, A. Salunke, and K. Bhalerao, "Harmonizing Algorithms: An Approach to Enhancing Audio Deepfake Detection," *International Journal of Intelligent Systems and Applications in Engineering (IJISAE)*, vol. 12, no. 4, pp. 137–144, 2024.
- [7] Y. Li, J. Jiang, and X. Wang, "SafeEar: Content Privacy-Preserving Audio Deepfake Detection," *arXiv preprint arXiv:2409.09272*, 2024.
- [8] T. Singh and P. K. Sharma, "Hybrid Audio Authentication Using SVM and MFCC Feature Fusion," *IEEE Transactions on Multimedia*, vol. 26, no. 8, pp. 4215–4228, 2024.
- [9] A. van den Oord, S. Dieleman, H. Zen, K. Simonyan, O. Vinyals, A. Graves, N. Kalchbrenner, A. Senior, and K. Kavukcuoglu, "WaveNet: A Generative Model for Raw Audio," *arXiv preprint arXiv:1609.03499*, 2016.

